



Evaluación Final Transversal

Minería de Datos - BIY7121

Predicción de lluvia al día siguiente usando weatherAUS.csv

Datos del encargo

Asignatura	BIY7121 - Minería de Datos
Sección	BIY7121-004D
Integrantes	Diego Casanova / José Soto
Dataset	weatherAUS.csv
Metodología	CRISP-DM
Fecha	2026

Tabla de contenido

Contenido

1. Introducción	3
2. Metodología	4
3. Preparación de los datos.....	5
4. Aplicación de técnicas de minería de datos.....	6
5. Modelos predictivos.....	7
6. Descubrimiento de patrones	8
7. Documentación, conclusiones y automatización.....	9
8. Recomendaciones	10
9. Referencias.....	11

1. Introducción

El propósito del proyecto es aplicar minería de datos sobre weatherAUS.csv para anticipar si lloverá al día siguiente en distintas zonas de Australia. La variable objetivo es RainTomorrow, por lo que el problema se aborda como una clasificación binaria: Sí llueve o No llueve.

En una organización, anticipar lluvia permite planificar rutas, turnos, seguridad en actividades al aire libre, mantención preventiva y protección de materiales. La minería de datos aporta valor porque transforma registros históricos en patrones medibles y en un modelo que puede estimar riesgo futuro a partir de variables meteorológicas disponibles antes de la decisión.

- El dataset contiene 142.193 registros y 24 columnas originales.
- La clase positiva es minoritaria: 22,42% de los registros indican lluvia al día siguiente.
- Se excluyó RISK_MM del modelamiento porque corresponde a lluvia futura medida y produciría fuga de información.

2. Metodología

El trabajo se estructuró con CRISP-DM, metodología adecuada porque ordena un proyecto de minería de datos desde la comprensión del problema hasta la evaluación y el despliegue esperado. Este enfoque permite justificar cada decisión y mantener trazabilidad entre el objetivo de negocio, los datos, las técnicas aplicadas y los resultados.

Fase	Aplicación en el proyecto
Comprensión del negocio	Predecir lluvia de mañana para apoyar decisiones operativas.
Comprensión de datos	Revisión de estructura, nulos, tipos, desbalance, correlaciones y comportamiento por ubicación/mes.
Preparación	Limpieza de textos, conversión de fechas, imputación de nulos, codificación categórica y escalamiento.
Modelamiento	Baseline, regresión logística y árbol de decisión para clasificación; K-Means para perfiles climáticos.
Evaluación	Accuracy, precision, recall, F1, ROC-AUC y matriz de confusión.
Despliegue esperado	Pipeline reproducible, archivo de métricas, modelo guardado y propuesta de automatización.

Las técnicas fueron seleccionadas por su coherencia con el problema: clasificación para predecir RainTomorrow y clustering para descubrir perfiles de días meteorológicos. La regresión logística aporta interpretabilidad; el árbol permite contrastar reglas no lineales; y K-Means ayuda a observar patrones sin usar la etiqueta como entrada.

3. Preparación de los datos

La obtención de datos se realizó desde el archivo weatherAUS.csv entregado para la evaluación. Antes del análisis se consideró la posibilidad de columnas con espacios, valores vacíos y tipos mezclados. Por eso se aplicó una limpieza preventiva: normalización de nombres de columnas, limpieza de textos, conversión de Date a fecha, validación de duplicados y revisión de valores faltantes.

Variable	Tipo	Nulos	% nulos
Sunshine	float64	67.816	47,69%
Evaporation	float64	60.843	42,79%
Cloud3pm	float64	57.094	40,15%
Cloud9am	float64	53.657	37,74%
Pressure9am	float64	14.014	9,86%
Pressure3pm	float64	13.981	9,83%




Figura 1. Variables con mayor ausencia de datos.

Los valores faltantes no se eliminaron masivamente porque algunas variables con muchos nulos siguen siendo relevantes. Las variables numéricas se imputaron con la mediana y las categóricas con la moda. La fecha se transformó en variables temporales como año y mes.

4. Aplicación de técnicas de minería de datos

Primero se realizó análisis exploratorio para comprender la distribución de RainTomorrow y sus relaciones principales. Luego se aplicaron técnicas supervisadas y no supervisadas. En supervisado, se entrenaron modelos para estimar la probabilidad de lluvia al día siguiente. En no supervisado, se usó K-Means para descubrir perfiles de días meteorológicos.




Figura 2. Distribución de la variable objetivo RainTomorrow.




Figura 3. Variables más relacionadas con la lluvia del día siguiente.

El análisis confirma señales coherentes: mayor humedad en la tarde, mayor nubosidad y menor sunshine se asocian con mayor probabilidad de lluvia. También se observa que haber tenido lluvia en el día actual eleva el riesgo de lluvia al día siguiente.

5. Modelos predictivos

El dataset fue dividido en entrenamiento y prueba usando estratificación para mantener la proporción de días con y sin lluvia. Como la clase Sí es minoritaria, se usaron métricas que no dependieran solo del accuracy. La métrica F1 se consideró clave porque equilibra precisión y recall, y ROC-AUC se usó para medir capacidad de discriminación del modelo.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión logística	0,796	0,531	0,780	0,632	0,873
Árbol de decisión	0,772	0,494	0,750	0,596	0,845
Baseline mayoría	0,776	0,000	0,000	0,000	0,500




Figura 4. Comparación de métricas entre modelos.




Figura 5. Matriz de confusión del modelo seleccionado.

El modelo con mejor desempeño general fue Regresión Logística, con F1 = 0,632 y ROC-AUC = 0,873. El recall alcanzó 0,780, por lo que identifica una proporción importante de los días que efectivamente terminan con lluvia.

6. Descubrimiento de patrones

Además del modelo predictivo, se identificaron patrones relevantes para la toma de decisiones. La ubicación, la humedad, la nubosidad, la presión y la estacionalidad muestran comportamientos claros. Portland, Walpole, Cairns, Dartmoor y Norfolk Island presentan mayor frecuencia histórica de lluvia al día siguiente; Woomera, Uluru y Alice Springs aparecen entre las zonas de menor riesgo relativo.



Figura 6. Ubicaciones con mayor frecuencia de lluvia al día siguiente.




Figura 7. Estacionalidad del riesgo de lluvia por mes.

7. Documentación, conclusiones y automatización

El proceso quedó documentado en el notebook, en el informe y en archivos de salida con métricas, perfil de calidad, resultados por ubicación, resultados por mes y perfiles de clustering. Los principales desafíos fueron el desbalance de la variable objetivo, la presencia de valores faltantes relevantes y el riesgo de fuga de información por RISK_MM.

Cluster	Días	Riesgo lluvia	Hum. 3pm	Lluvia mm	Temp. 3pm
0	23.201	60,1%	69,3	9,18	17,2
1	24.346	4,3%	37,4	0,40	22,0
2	42.334	14,8%	40,4	0,91	29,5
3	52.312	20,3%	59,1	1,40	17,3




Figura 8. Riesgo de lluvia según perfil meteorológico.

Como conclusión, el dataset permite construir una solución predictiva útil y explicable. El modelo no reemplaza el criterio meteorológico profesional, pero sí permite priorizar días y zonas con mayor riesgo. La automatización propuesta consiste en cargar diariamente nuevos registros, validar calidad, aplicar el pipeline, generar una probabilidad de lluvia, almacenar resultados y emitir alertas por rango de riesgo.

8. Recomendaciones

- Usar el modelo como apoyo preventivo, especialmente cuando se busca reducir el riesgo de no detectar días lluviosos.
- No utilizar RISK_MM como predictor en producción, porque representa información futura que no estaría disponible al momento de decidir.
- Monitorear precision, recall, F1 y ROC-AUC en el tiempo, ya que cambios climáticos o cambios de estaciones pueden afectar el rendimiento.
- Crear un tablero simple por ubicación, fecha y nivel de riesgo, priorizando zonas con mayor frecuencia histórica de lluvia.
- Ampliar el proyecto incorporando pronósticos oficiales, coordenadas geográficas y validación temporal para simular mejor el uso real.

Siguientes pasos sugeridos: probar umbrales de alerta según costos del negocio, guardar las predicciones diarias en una base histórica y ejecutar una revisión mensual de métricas. Esto permite que el sistema no sea solo un modelo aislado, sino una herramienta permanente de apoyo a la decisión.

9. Referencias

- Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide.
- Kuhn, M. & Johnson, K. (2013). Applied Predictive Modeling. Springer.
- Pandas Development Team. Documentación oficial de pandas.
- Scikit-learn Developers. Documentación oficial de scikit-learn.
- Matplotlib Development Team. Documentación oficial de Matplotlib.
- Dataset utilizado: weatherAUS.csv, archivo entregado para la evaluación BIY7121.